Architettura a Microservizi

Progettazione, simulazione e valutazione delle prestazioni

Jacopo Fabi 0293870
Davide Bianchi 0293906

AA 2022/2023

Indice

1 Introduzione

Il continuo sviluppo in ambito tecnologico, con il passare del tempo, ha generato soluzioni innovative per le aziende, molte delle quali si sono adeguate così da organizzare e gestire al meglio la loro infrastruttura IT.

Il caso di studio in esame prende in considerazione un'architettura a micro-servizi di proprietà di un'azienda che offre al pubblico la possibilità di effettuare prenotazioni per viaggi verso mete turistiche.

Non disponendo di uno scenario reale di riferimento, ci si è posti in una condizione verosimile di un'infrastruttura mal dimensionata in fase di sviluppo:

- Si parte da una possibile architettura già esistente che presenta diversi problemi introdotti dall'errata progettazione iniziale.
- Si cerca di identificare la soluzione migliore che permetta all'azienda che ha commissionato il lavoro di raggiungere i suoi obiettivi.

L'architettura dell'azienda offre molteplici alternative ai clienti, per questo motivo è caratterizzata da più micro-servizi, ognuno dei quali si occupa di gestire una precisa prenotazione:

- Gli utenti che vogliono prenotare un biglietto aereo hanno la possibilità di prenotare un pacchetto completo aggiungendo un soggiorno in hotel e il noleggio di un'automobile per tutto il periodo di residenza.
- Gli utenti che vogliono prenotare un soggiorno in hotel hanno solamente la possibilità di aggiungere il noleggio di un'automobile per tutto il periodo di residenza.

Per completare la prenotazione del pacchetto vacanza è necessario che il pagamento vada a buon fine, per questo motivo ogni utente verrà re-direzionato, come ultimo step, verso un micro-servizio che si occupa della convalida finale: la prenotazione verrà confermata solamente se il pagamento dell'utente non presenta problemi.

Di seguito si riporta un'immagine rappresentativa dell'architettura in esame:

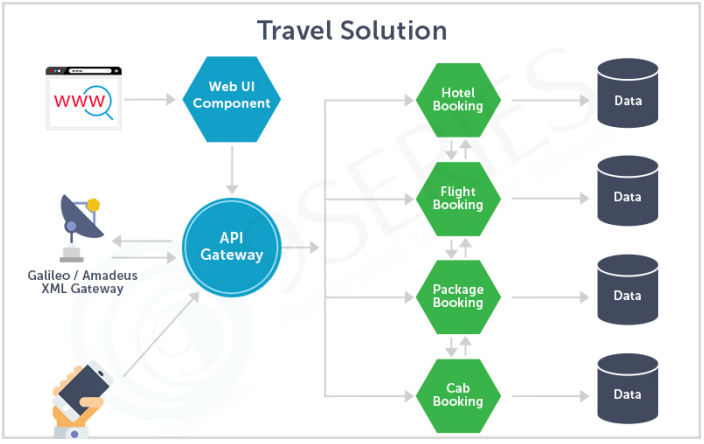

2 Obiettivo

Con il passare del tempo, l'utilizzo del sistema ha subito un incremento significativo che lo ha reso inadatto a soddisfare il nuovo carico di lavoro, in particolare l'azienda ha iniziato a sperimentare:

- Tempi di risposta troppo lunghi.
- Numero eccessivo di operazioni di convalida del pagamento non processate.

L'obiettivo dello studio è quindi quello di mitigare tali problemi minimizzando i costi di implementazione della soluzione.

A tale scopo, i due **QoS** che si vogliono rispettare sono:

- Mantenere la somma dei tempi medi di risposta di tutti i micro-servizi al di sotto dei 12 secondi, senza considerare i tempi di percorrenza da uno all'altro.
- Processare almeno il 95% delle prenotazioni richieste dagli utenti.

A tale scopo si effettua uno studio sia del transiente che dello stato stazionario per individuare quale configurazione rispetta i due vincoli prefissati, garantendo il minor costo totale (inteso come numero di serventi aggiunti).

Il primo QoS ha l'obiettivo di garantire un tempo ragionevole per il completamento delle prenotazioni più impegnative per il sistema, ovvero quelle che attraversano tutti i micro-servizi dell'architettura (prenotazioni per pacchetto completo).

Il secondo QoS, invece, deriva dalle segnalazioni di molti utenti che lamentano l'impossibilità di procedere con la convalida del pagamento, e quindi sono costretti a ripetere l'intera procedura di prenotazione.

Ogni servente attivo implica un costo più elevato di gestione, ecco perché l'obiettivo è quello di identificare il numero minimo di serventi che sia in grado di soddisfare anche un carico di lavoro molto alto minimizzando le spese e rispettando i due QoS.

3 Modello Concettuale

A partire dall'architettura esistente dell'azienda è stato prodotto il relativo modello concettuale riportato in figura: ogni micro-servizio è in esecuzione su un server dedicato che è caratterizzato da molteplici repliche, ciascuna eseguita su un container.

Dalla rete si possono evidenziare quattro *nodi* (o sottosistemi) differenti:

- Nodo 1: Prenotazione Volo
- Nodo 2: Prenotazione Hotel
- Nodo 3: Prenotazione Noleggio
- Nodo 4: Convalida Pagamento

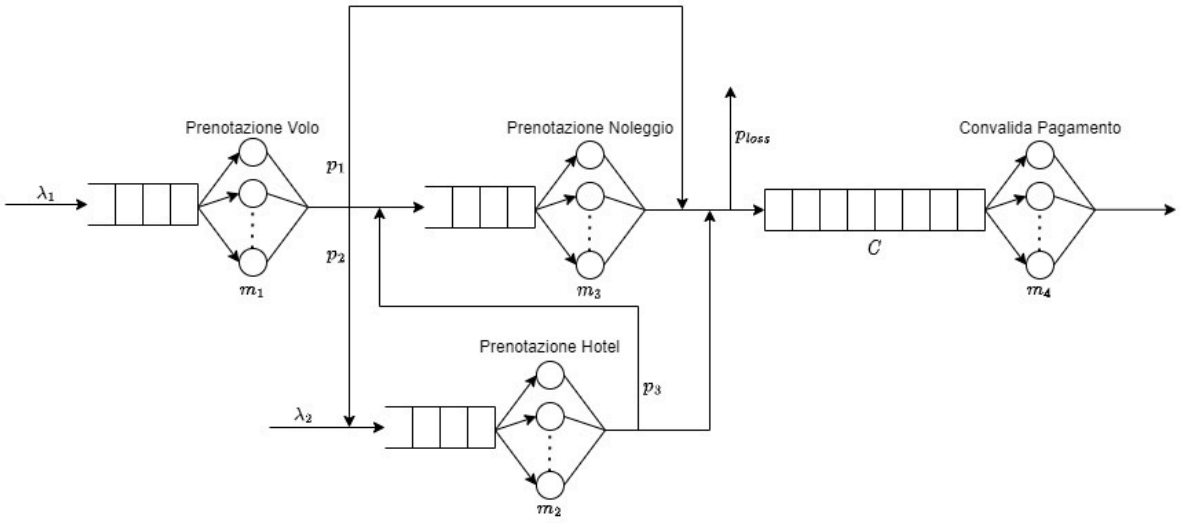

Un cliente ha la possibilità di effettuare prenotazioni per pacchetti differenti in base alle sue necessità: la prenotazione del volo permette di includere nel pacchetto un soggiorno in hotel e il noleggio di un'automobile, la prenotazione dell'hotel è invece dedicata a quei clienti che non hanno la necessità di acquistare biglietti aerei ma che in caso di necessità possono noleggiare un'automobile.

I primi tre nodi sono stati modellati con una **M/M/m** perché sono in grado di gestire tutte le prenotazioni in arrivo.

Il nodo per la convalida del pagamento è stato invece modellato con una **M/M/m/C** perché, in base ai dati ricevuti dall'azienda che ha commissionato il lavoro, è l'unico che non elabora parte delle richieste in arrivo, scartandole:

- La scelta di limitare la capacità dell'ultimo nodo, in fase di sviluppo, fu presa per garantirne la stabilità, scartando una bassa percentuale di richieste.
- Nel momento in cui il carico di lavoro ha subito un incremento nel tempo, l'azienda ha riscontrato una percentuale eccessiva di scarti che limita significativamente i ricavi.

I tempi di interarrivo sono modellati con una distribuzione esponenziale perché è scientificamente dimostrato che arrivi indipendenti tra loro siano distribuiti esponenzialmente, quindi è un'ottima scelta per rappresentare occorrenze randomiche.

Per quanto riguarda i tempi di servizio, la scelta di modellarli come una variabile aleatoria esponenziale deriva dal fatto che questa distribuzione rappresenta molto bene le caratteristiche dei micro-servizi:

- Range temporale da 0 a infinito con molto più alta densità sui valori piccoli
- Tempi più grandi sono relativi a problematiche hardware legate alla cache, accessi in memoria, ecc, e sono molto rari

Le **variabili di stato** considerate sono:

- Stato di un servente (IDLE/BUSY)
- Numero di richieste in uno specifico nodo

Gli **eventi** che possono verificarsi sono:

- Arrivo di una richiesta
- Servizio di una richiesta presso il servente assegnato

Gli **utenti** in ingresso al sistema sono di due tipi e questa distinzione viene utilizzata solamente all'interno dell'algoritmo migliorativo:

- Iscritti
- Visitatori

Un'architettura a micro-servizi offre al pubblico un servizio web che è disponibile 24 ore al giorno, con un numero di clienti che può variare nell'arco della giornata, ma che comunque non permette di identificare slot orari con tassi di richieste differenti:

- Essendo il servizio fruibile da ogni parte del mondo, eventuali picchi diurni sono mitigati in media dalla quasi totale inattività notturna dall'altra parte del mondo, garantendo una certa stabilità degli arrivi.
- Inoltre, un sistema distribuito utilizza tecniche come l'autoscaling che permettono al sistema di reagire a variazioni improvvise del carico adattando a run-time il numero di serventi sui diversi nodi.
- Ha poco senso quindi effettuare un dimensionamento per fasce orarie nella singola giornata, ma risulta comunque complesso simulare l'autoscaling dovendo costantemente analizzare il tasso d'arrivo nell'ultimo periodo, ad esempio negli ultimi 30 secondi, per adattare il sistema.

Per le motivazioni appena descritte, lo studio mira a dimensionare l'architettura a livello della singola giornata, considerando un tasso di arrivo costante.

4 Modello delle Specifiche

4.1 Dati di Input

Come già detto in precedenza, le specifiche del sistema iniziale non fanno riferimento a dati reali ma sono dati verosimili per la rappresentazione di un caso reale in condizioni critiche di utilizzo.

La configurazione iniziale del sistema commissionato è la seguente:

- m_k = numero di serventi del nodo k
  - $m_1 = 4$
  - $m_2 = 4$
  - $m_3 = 2$
  - $m_4 = 2$
- C_k = capacità della coda del nodo k
  - $C_1 = \infty$
  - $C_2 = \infty$
  - $C_3 = \infty$
  - $C_4 = 8$
- Per semplicità, si utilizza $C_4 = C$ essendo l'unico nodo con coda finita

I dati forniti dall'azienda che ha commissionato il lavoro sono i seguenti:

- Numero di clienti al giorno: 240.000 circa
  - 1,9 arrivi medi al secondo per prenotazioni di voli
  - 0,8 arrivi medi al secondo per prenotazioni di hotel
- Tempo di prenotazione volo: 2 secondi
  - 0.5 prenotazioni al secondo
- Tempo di prenotazione hotel: 3,2 secondi
  - 0,3 prenotazioni al secondo
- Tempo di prenotazione noleggio: 2,5 secondi
  - 0,4 prenotazioni al secondo
- Tempo di convalida pagamento: 1,3 secondi
  - 0,77 convalide di prenotazioni al secondo
- Percentuale di utenti che prenotano soltanto il volo: $p_1 = 65\%$
- Percentuale di utenti che prenotano oltre al volo un hotel: $p_2 = 20\%$
- Percentuale di utenti che oltre all'hotel noleggiano un veicolo: $p_3 = 40\%$

4.2 Probabilità di Routing

Il flusso totale in ingresso viene distribuito verso i vari nodi tramite le **probabilità di routing**, definite sfruttando le percentuali descritte in precedenza:

- Probabilità di uscita dalla prenotazione del volo
  - Convalida Pagamento: $p_1 = 0{,}65$
  - Prenotazione Hotel: $p_2 = 0.20$
  - Prenotazione Noleggio: $1\text{-}p_1\text{-}p_2 = 0.15$
- Probabilità di uscita dalla prenotazione dell'hotel
  - Prenotazione Noleggio: $p_3 = 0{,}40$
  - Convalida Pagamento: $1\text{-}p_3 = 0.60$
- La probabilità di uscita dai nodi 3-4 è pari ad 1, questo perché la destinazione è deterministica
  - Ovviamente, c'è una percentuale p_{loss} che viene scartata dal nodo di convalida a causa della coda finita.
  - In questo caso, però, non c'è destinazione, ma la richiesta viene rigettata dal sistema.

5 Modello Computazionale

Per la simulazione della rete è stato utilizzato l'approccio di tipo **Next-Event Simulation**, in cui l'avanzamento del tempo si effettua tramite processamento dell'evento successivo.

Il modello è sviluppato in linguaggio C sfruttando le librerie di Larry Leemis descritte al link *http://www.math.wm.edu/~leemis/simtext.code.c*: in particolare si utilizzano i files *rngs.h*, *rvgs.h* e *rvms.h* rispettivamente per la generazione di numeri random, di variabili aleatorie ed intervalli di confidenza.

In particolare, questa libreria fornisce l'implementazione del generatore di Lehmer, un generatore molto utilizzato e largamente accettato sulla base dei seguenti criteri:

- Randomicità, produce risultati molto vicini ad un generatore ideale.
- Controllabilità, capace di riprodurre lo stesso output in run differenti.
- Portabilità, capace di produrre lo stesso output su macchine differenti.
- Efficienza, veloce e con requisiti hardware minimi per l'utilizzo.
- Documentazione, analizzato teoricamente e testato.

Tramite questo generatore è possibile anche produrre più streams, utili per eseguire simulazioni tra loro indipendenti.

Il codice della simulazione è implementato nel file *microservices.c*.

Nella directory */lib* troviamo le librerie descritte in precedenza con l'aggiunta della libreria custom *utils.h* che contiene diverse funzioni user-defined utilizzate all'interno dell'implementazione per rendere il codice più ordinato.

Infine, nel file *config.h* troviamo la definizione delle strutture utilizzate all'interno della simulazione e i parametri di configurazione globale del sistema.

5.1 Strutture Dati

Descriviamo le principali strutture dati utilizzate all'interno della simulazione:

- Struttura *node_stats* che mantiene le informazioni sul singolo nodo.
    - Mantiene il riferimento ai server associati e informazioni sulle statistiche individuali (jobs in coda, jobs in servizio, jobs processati, …).
    - La coda del nodo è implementata come una *linked list* di job in cui ogni job punta a quello successivo.
- Struttura *server_stats* che mantiene le informazioni sul singolo servente.
    - Mantiene il riferimento al job in servizio (se presente) e informazioni sulle statistiche individuali (stato, jobs processati, ultima uscita, …).

- Struttura *event* che rappresenta la lista degli eventi.
    - Memorizza il tipo di evento (arrivo o fine servizio), il nodo su cui l'evento avviene, il server che deve servire il job, l'istante di tempo in cui inizia l'evento e il riferimento al prossimo evento più imminente.
- Struttura *analysis* che mantiene le statistiche medie temporanee prodotte da una singola run della simulazione (replica/batch).
- Struttura *statistic_analysis* che mantiene le statistiche medie finali prodotte dall'esecuzione dell'intera simulazione e gli intervalli di confidenza.
- Per mantenere il tempo di simulazione si usa la variabile globale *current_time.*

5.2 Gestione degli eventi

Gli eventi di arrivo e di completamento vengono gestiti in maniera differente, per questo motivo si verifica sempre se il prossimo evento è un arrivo o un completamento. Per l'implementazione della event_list, all'estrazione di un evento questo viene direttamente eliminato dalla lista:

1. Si estrae il primo evento disponibile dalla event_list tramite ExtractEvent().
2. Si controlla il tipo di evento e si processa un arrivo (*job_arrival*) o una partenza (*job_departure*) sul nodo corrispondente.

5.2.1 Arrivo

La event_list viene inizializzata generando degli eventi iniziali tramite GenerateEvent() questi sono arrivi dall'esterno con tempo di arrivo ottenuto da GetInterArrival() che utilizza la funzione Exponential() di rvgs.h.

Ogni arrivo dall'esterno viene gestito dal nodo per la prenotazione del volo o per la prenotazione dell'hotel.

Se c'è un servente libero, quindi il numero di job nel nodo è minore dei servers totali, si assegna l'evento al servente libero da più tempo tramite SelectServer():

1. Si genera un job per il processamento dell'evento di arrivo tramite GenerateJob() con tempo di servizio esponenziale tramite GetService().
2. Si registra il job nel nodo assegnandolo a un servente libero tramite SelectServer().
3. Si setta lo stato del server come BUSY e si assegna il job attualmente in servizio.
4. Si genera un evento di completamento per il servente in questione tramite GenerateEvent() e si inserisce nella event_list tramite InsertEvent().

Se non c'è alcun servente libero nel nodo, il job viene inserito nella coda del nodo, a patto che la coda sia infinita o che ci sia spazio in una coda finita.

5.2.2 Completamento

Quando viene processato un completamento, sì aggiornano le statistiche del servente in questione (jobs processati, jobs nel nodo, …) e si rimuove il job che era in servizio.

A questo punto, se ci sono jobs in coda, si estrae il primo (secondo la politica FIFO) e si mette subito in servizio, altrimenti si setta lo stato del server come IDLE.

Il completamento di un servente equivale ad un arrivo sul nodo successivo:

1. Tramite il metodo SwitchNode() si seleziona il nodo successivo che deve processare l'evento in esame secondo le probabilità di routing prima descritte.
    - Si genera un valore casuale tra 0 e 1 tramite Random() e si confronta con le diverse probabilità, individuando il nodo di destinazione.
2. Si genera un evento di arrivo sul nodo selezionato tramite GenerateEvent() e si inserisce nella event_list tramite InsertEvent().

5.3 Simulazione ad Orizzonte Finito

Nella simulazione ad orizzonte finito il sistema viene simulato per un tempo pari a quello della singola giornata (24 ore) facendo fede al tempo del caso di studio reale: in questo modo si producono le cosiddette statistiche transienti del sistema.

Per ricavare la media campionaria del tempo di risposta si utilizzano 64 repliche della singola run di simulazione:

- Risulta essere il giusto compromesso tra dimensione degli intervalli di confidenza prodotti e tempo di simulazione.
- Essendo > 40 consente l'utilizzo della gaussiana in sostituzione della t-student per semplificare il calcolo dell'intervallo di confidenza.

Si esegue quindi un ensamble di dimensione pari a 64 repliche di simulazione:

- Ogni replica viene utilizzata per misurare le stesse statistiche da cui verranno poi ricavati i valori finali come media campionaria.
- Per gli intervalli di confidenza, si usa un livello di confidenza pari a 95%
    - Si utilizza l'algoritmo di Welford per la generazione degli stessi.
- Il seed viene impostato tramite PlantSeeds() fuori dal ciclo di replicazione, nelle repliche successive alla prima invece viene usato come stato iniziale del generatore random lo stato finale degli streams della replica precedente [1].
    - Evitiamo sovrapposizioni degli eventi generati dalle singole repliche.
- Il termine della simulazione è legato alla fine della giornata, ovvero quando il clock di simulazione raggiunge 86400 secondi (24 ore).

L'obiettivo della simulazione ad orizzonte finito per il caso di studio in esame è principalmente uno:

- Analizzare i tempi di convergenza del sistema oppure una sua eventuale divergenza.

5.4 Simulazione ad Orizzonte Infinito

In una simulazione ad orizzonte infinito, si simula il sistema per un *lungo* periodo di tempo, al fine di ottenere una buona stima puntuale per ogni statistica di interesse.

Per ricavare la media campionaria del tempo di risposta si utilizza il metodo delle **Batch Means**, che opera suddividendo l'esecuzione della simulazione in **K** batches di dimensione **B**:

- Si ricavano le statistiche tramite extract_analysis() e si resettano questi valori tramite reset_stats() per ogni singolo batch.
    - Si resettano soltanto i valori degli integrali così da reinizializzare i valori per l'esecuzione del batch successivo.
    - Lo stato del sistema non viene alterato e si mantengono tutti i job rimanenti dal precedente batch.
- Inoltre, si mantiene invariato anche lo stato del generatore random.
    - Ciò consente di avere indipendenza tra i vari batch, a patto che la loro dimensione sia abbastanza grande [2].
- Per gli intervalli di confidenza, si usa un livello di confidenza pari a 95%.
    - Si utilizza l'algoritmo di Welford per la generazione degli stessi.

In questo modo si genera un campione di K batches indipendenti, sul quale è possibile valutare la media campionaria.

Le dimensioni di B e K impattano sulla qualità del campione, un valore di B grande permette di avere un campione con bassa autocorrelazione mentre un numero K più grande di batch fornisce un valore migliore in termini di intervallo di confidenza:

- Per tale motivo sono stati utilizzati K = 64 batch, valore che risulta essere un buon compromesso come riportato in letteratura.
- Il numero di jobs scelto è pari a B = 18000 che è un buon compromesso tra l'indipendenza dei batch [2] e la capacità della simulazione di tenere conto della variabilità del sistema.
- In totale, per una run di simulazione sono processati B*K=1.152.000 jobs, che si traduce in un tempo di simulazione di circa 5 giorni.

Gli obiettivi della simulazione ad orizzonte infinito per il caso di studio in esame sono principalmente due:

- Analisi della stazionarietà del sistema.
- Ottenere i valori medi per la fase di verifica, prima e dopo il suo ridimensionamento.

6 Verifica

In questo capitolo si vuole accertare che il modello computazionale è effettivamente *conforme al modello delle specifiche* e che i valori di output siano coerenti tra loro, quindi, si vuole provare che l'implementazione del modello computazionale sia effettivamente corretta.

Per la fase di verifica si utilizza l'output di un'analisi ad orizzonte infinito basata su una simulazione suddivisa in 64 batches con il 95% di confidenza:

- Fissati B, K e il grado di confidenza, tanto più gli intervalli prodotti sono piccoli, tanto più significa che la statistica misurata converge rapidamente al valore atteso.

Risultati nodo 1

Tempo di interarrivo medio	0.527084 +/- 0.00016
Tempo di risposta medio	10.713076 +/- 0.727249
Tempo di attesa medio	8.713345 +/- 0.724623
Tempo di servizio medio	1.99971 +/- 0.004649
Numero di richieste medio nel nodo	20.371434 +/- 1.389638
Numero di richieste medio nella coda	16.569862 +/- 1.383696
Utilizzazione media	0.950383 +/- 0.00233
Probabilità di perdita	0.00% +/- 0.00%

Risultati nodo 2

Tempo di interarrivo medio	0.849705 +/- 0.002306
Tempo di risposta medio	15.072952 +/- 1.0235
Tempo di attesa medio	11.867771 +/- 1.018367
Tempo di servizio medio	3.205151 +/- 0.008332
Numero di richieste medio nel nodo	17.791919 +/- 1.22514
Numero di richieste medio nella coda	14.012061 +/- 1.215717
Utilizzazione media	0.944956 +/- 0.003072
Probabilità di perdita	0.00% +/- 0.00%

Risultati nodo 3

Tempo di interarrivo medio	1.323486 +/- 0.004526
Tempo di risposta medio	22.080547 +/- 2.26822
Tempo di attesa medio	19.581066 +/- 2.263099
Tempo di servizio medio	2.499467 +/- 0.008771
Numero di richieste medio nel nodo	16.751419 +/- 1.746841
Numero di richieste medio nella coda	14.858862 +/- 1.74061
Utilizzazione media	0.946273 +/- 0.00426
Probabilità di perdita	0,00% +/- 0,00%

Risultati nodo 4

Tempo di interarrivo medio	0.650662 +/- 0.001806
Tempo di risposta medio	5.660266 +/- 0.021918
Tempo di attesa medio	4.361712 +/- 0.018363
Tempo di servizio medio	1.298552 +/- 0.003688
Numero di richieste medio nel nodo	8.716019 +/- 0.013919
Numero di richieste medio nella coda	6.716307 +/- 0.011594
Utilizzazione media	0.999855 +/- 0.001836
Probabilità di perdita	42.96% +/- 0.1934%

Per il caso di studio in esame, la verifica consiste nell'accertarsi che i flussi in arrivo ai nodi ed i tempi di servizio degli stessi, siano coerenti con quelle del modello delle specifiche, quindi che:

1. Il tempo medio di inter-arrivo su un nodo deve essere uguale all'inverso del suo flusso entrante, relativamente alle probabilità di routing dichiarate nel modello delle specifiche
2. Il tempo medio di servizio deve essere pari a quello riportato nel modello delle specifiche

Di seguito è riportata la verifica:

1. $\frac{1}{flusso\ entrante} \approx i$
    a. $f_1 = a_1 = 1.9 \rightarrow \frac{1}{1,9} \approx 0.527084 \approx i_1$
    b. $f_2 = a_2 + p_2 f_1 = 1.18 \rightarrow \frac{1}{1,18} \approx 0.849705 \approx i_2$
    c. $f_3 = (1 - p_1 - p_2) f_1 + p_3 f_2 = 0.757 \rightarrow \frac{1}{0.757} \approx 1.323486 \approx i_3$
    d. $f_4 = ((1 - p_3) f_2 + p_1 f_1 + f_3)(1 - p_{loss}) = 1.5352 \rightarrow \frac{1}{1.5352} \approx 0.650662 \approx i_4$

2. $E(S_i) \approx specifica$
    a. $1.99971 \approx 2.0 \approx E(S_{1,i})$
    b. $3.205151 \approx 3.2 \approx E(S_{2,i})$
    c. $2.499467 \approx 2.5 \approx E(S_{3,i})$
    d. $1.298552 \approx 1.3 \approx E(S_{4,i})$

Gli ulteriori controlli di consistenza realizzati sono i seguenti:

1. La popolazione media in un nodo deve essere uguale alla somma tra quella in coda e quella mediamente in servizio (pari a m volte il tasso di utilizzazione)
2. Il tempo di risposta di un nodo deve essere uguale alla somma tra il tempo medio in coda ed il tempo medio di servizio
3. Deve valere la legge di Little
    a. La popolazione media in un nodo deve essere uguale al prodotto tra il tempo medio di risposta del nodo e il suo flusso entrante
    b. La popolazione media in coda di un nodo deve essere uguale al prodotto tra il tempo medio in coda del nodo e il suo flusso entrante

Di seguito è riportata la verifica:

1. $E(N_Q) + E(c) \approx E(N_S)$
    - $16.692665 + 4 * 0949774 = 20.491761 \approx E(N_{S,1})$
    - $14.762341 + 4 * 0.944046 = 18.538526 \approx E(N_{S,2})$
    - $16.059211 + 2 * 0.946238 = 17.951687 \approx E(N_{S,3})$
    - $6.7090130 + 2 * 0.997933 = 8.7048790 \approx E(N_{S,4})$

2. $E(T_Q) + E(S_i) \approx E(T_S)$
    - $8.785667 + 1.999562 = 10.785229 \approx E(T_{S,1})$
    - $12.509269 + 3.200106 = 15.709375 \approx E(T_{S,2})$
    - $21.210868 + 2.499753 = 23.71062 \approx E(T_{S,3})$
    - $4.369899 + 1.299999 = 5.669898 \approx E(T_{S,4})$

3. $N = \lambda T$
    a. $E(N_S) = f * E(T_S) = \frac{E(T_S)}{i}$
        - $10.785229/0.526375 = 20.489630 \approx E(N_{S,1})$
        - $15.709376/0.847526 = 18.535568 \approx E(N_{S,2})$
        - $23.710621/1.321021 = 17.948709 \approx E(N_{S,3})$
        - $5.669898/0.651407 = 8.704079 \approx E(N_{S,4})$

b. $E(N_Q) = f * E(T_Q) = \frac{E(T_Q)}{i}$

- $8.785667/0.526375 = 8.704079 \approx E(N_{Q,1})$
- $12.509269/0.847526 = 8.704079 \approx E(N_{Q,2})$
- $21.210868/1.321021 = 8.704079 \approx E(N_{Q,3})$
- $4.369899/0.651407 = 8.704079 \approx E(N_{Q,4})$

7 Validazione

In questa fase si vuole accertare che il modello computazionale è coerente con il sistema reale in esame, tuttavia, non avendo dati reali a disposizione, si opera una validazione rispetto al modello analitico; quindi, si verifica che i risultati ottenuti dalla simulazione rispettino effettivamente le leggi teoriche.

Come già detto, il caso di studio non è reale ma verosimile, tuttavia, si ha la conferma teorica che l'architettura usata come riferimento risponderà ***sicuramente*** alle leggi del modello analitico: i tempi di interarrivo e di servizio sono distribuiti esponenzialmente; pertanto, il sistema risponderà alle leggi teoriche.

Le leggi del modello analitico che caratterizzano i nodi **M/M/m** del sistema sono:

- $E(T_{Q,k}) = P_{Q,k}\frac{E(S,k)}{1-\rho_k}$ $\quad per\ i\ nodi\ con\ k \in [1,3]$
  - $P_{Q,k} = \frac{(m_k\rho_k)^{m_k}}{m_k!(1-\rho_k)}P_k(0)$
  - $P_k(0) = \left[\sum_{i=0}^{m_k-1}\frac{(m_k\rho_k)^i}{i!} + \frac{(m_k\rho_k)^{m_k}}{m_k!(1-\rho_k)}\right]^{-1}$
- $E(T_{S,k}) = E(T_{Q,k}) + E(S_{k,i})$ $\quad per\ i\ nodi\ con\ k \in [1,3]$
- $E(N_{Q,k}) = \lambda_k E(T_{Q,k})$ $\quad per\ i\ nodi\ con\ k \in [1,3]$
- $E(N_{S,k}) = \lambda_k E(T_{S,k})$ $\quad per\ i\ nodi\ con\ k \in [1,3]$

Per quanto riguarda il nodo **M/M/m/C**, invece, lo studio risulta essere più complesso perché è necessario derivare le formule che modellano un multi-server con capacità finita della coda analizzando la rispettiva catena di Markov:

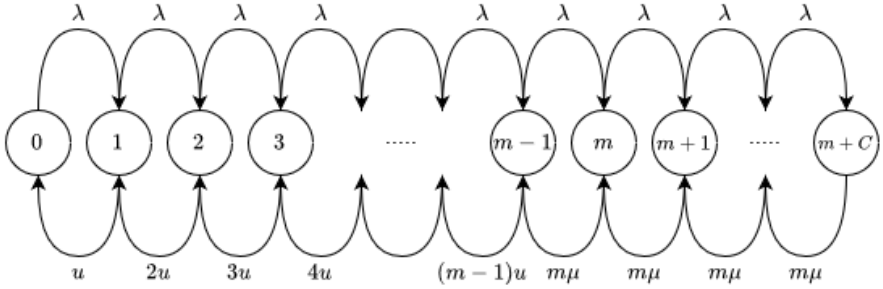

- Per prima cosa scriviamo le equazioni di *bilanciamento globale*, il flusso che entra nello stato S_i è uguale al flusso che esce dallo stato S_i
  - $(\lambda + (m-1)\mu)\pi_{m-1} = \pi_{m-2}\lambda + m\mu\pi_m \rightarrow \pi_m = \frac{1}{m!}\frac{\lambda^m}{\mu^m}\pi_0$
  - $(\lambda + m\mu)\pi_m = \pi_{m-1}\lambda + m\mu\pi_{m+1} \rightarrow \pi_{m+1} = \frac{1}{mm!}\frac{\lambda^{m+1}}{\mu^{m+1}}\pi_0$
  - $(\lambda + m\mu)\pi_{m+1} = \pi_m\lambda + m\mu\pi_{m+2} \rightarrow \pi_{m+2} = \frac{1}{m^2m!}\frac{\lambda^{m+2}}{\mu^{m+2}}\pi_0$
  - Si ottiene che $\pi_k = \begin{cases}\frac{1}{k!}(m\rho)^k\pi_0, \wedge\ k \le m \\ \frac{m^m}{m!}\rho^k\pi_0, \wedge\ k > m\end{cases}$ $dove\ \rho = \frac{\lambda}{m\mu}$

- Passiamo ora alla *condizione di normalizzazione* per ricavare π_0
  - $\sum_{i=0}^{m+C} \pi_i = 1 \rightarrow \left(\sum_{k=0}^{m-1} \frac{(m\rho)^k}{k!} + \frac{m^m}{m!}\sum_{m}^{m+C} \rho^k\right)\pi_0 = 1$
  - Si ottiene che $\pi_0 = \frac{1}{\sum_{k=0}^{m-1}\frac{(m\rho)^k}{k!} + \frac{m^m}{m!}\sum_{m}^{m+C}\rho^k} = \frac{1}{\sum_{k=0}^{m-1}\frac{(m\rho)^k}{k!} + \frac{(m\rho)^m}{m!}\sum_{k=0}^{C}\rho^k}$
- Deriviamo p_{loss}, $E(N_{S,4})$ ed $E(N_{Q,4})$
  - $p_{loss} = \pi_{m+C} = \frac{\frac{(m\rho)^m}{m!}\rho^C}{\sum_{k=0}^{m-1}\frac{(m\rho)^k}{k!} + \frac{(m\rho)^m}{m!}\frac{1-\rho^{C+1}}{1-\rho}}$
  - $E(N_{S,4}) = \sum_{k=0}^{m+C} k\pi_k = \frac{\sum_{k=0}^{m-1} k\frac{(m\rho)^k}{k!}\rho^C + \sum_{k=m}^{m+C} k\frac{m^m}{m!}\rho^k}{\sum_{k=0}^{m-1}\frac{(m\rho)^k}{k!} + \frac{(m\rho)^m}{m!}\frac{1-\rho^{C+1}}{1-\rho}}$
  - $E(N_{Q,4}) = E(N_{S,4}) - m\rho' = E(N_{S,4}) - m\rho(1 - p_{loss})$
- Deriviamo $E(T_{Q,4})$ ed $E(T_{S,4})$
  - Si applica la Legge di Little $N = \lambda T$, nel caso specifico in analisi si ha che $\lambda_4 = f_4(1 - p_{loss}) = (p_1 f_1 + (1 - p_3)f_2 + f_3)(1 - p_{loss})$
  - $E(T_{Q,4}) = \frac{E(N_{Q,4})}{\lambda_4} = \frac{E(N_{S,4}) - m\rho(1-p_{loss})}{((1-p_3)f_2 + p_1 f_1 + f_3)(1-p_{loss})}$
  - $E(T_{S,4}) = \frac{E(N_{S,4})}{\lambda_4} = \frac{E(N_{S,4})}{((1-p_3)f_2 + p_1 f_1 + f_3)(1-p_{loss})}$

A questo punto, abbiamo a disposizione tutte le leggi teoriche necessarie per verificare che effettivamente il modello computazionale è coerente con il modello analitico e quindi all'ipotetico caso reale di studio.

Come per la verifica, anche la validazione del sistema è stata eseguita sull'output della simulazione ad orizzonte infinito, di conseguenza sono riportati i risultati di questa run rispetto al modello analitico:

	Modello Analitico	**Modello Sperimentale** ($\alpha = 0.01$)
$E(N_{S,1})$	20.736960908382	20.371434 +/- 1.389638
$E(N_{S,2})$	18.588599371818	17.791919 +/- 1.22514
$E(N_{S,3})$	18.0908425565298	16.751419 +/- 1.746841
$E(N_{S,4})$	8.70668118927952	8.716019 +/- 0.013919
$E(T_{Q,1})$	8.91418995178	8.713345 +/- 0.724623
$E(T_{Q,2})$	12.5530503151	11.867771 +/- 1.018367
$E(T_{Q,3})$	21.3980747114	19.581066 +/- 2.263099

$E(T_{Q,4})$	4.37035814768	4.361712 +/- 0.018363
p_{loss}	43.142107411 %	42.9553% +/- 0.1934%
$E(T_{S,tot})$	56.236731259	53.5268 +/- 2.7678

Con $E(T_{S,tot})$ si fa riferimento alla somma dei tempi medi di risposta dei singoli nodi del sistema, ovvero il tempo che impiega una richiesta generica per completare il percorso che attraversa tutti quanti i micro-servizi dell'architettura:

- Prenotazione e convalida di un pacchetto vacanza con hotel, aereo e noleggio
- $E(T_{S,tot}) = E(T_{S,1}) + E(T_{S,2}) + E(T_{S,3}) + E(T_{S,4}) = \sum_k \left(E(T_{Q,k}) + E(S_{k,i})\right)$

8 Ridimensionamento

Per osservare graficamente le funzioni che descrivono gli indici di prestazione del modello analitico al variare dell'utilizzazione e del numero di serventi, si è fatto uso del generatore online di grafici di funzione Desmos, accessibile ai seguenti links:

- Microservices base
- Microservices_resized
- Microservices_improved

In particolare, di seguito si propongono le formule e i grafici del modello analitico relativi agli indici prestazionali del nodo con coda limitata:

- Tutte le leggi sono in funzione del tasso di utilizzazione x
- Le leggi dei tempi sono ricavate applicando la legge di Little $\frac{N}{\lambda}$
    - λ è espresso come il prodotto tra il tasso di utilizzazione x e $m\mu$

30

$$p_{loss4}(x) = \frac{\frac{(m_4 x)^{m_4} x^{C_4}}{m_4!}}{\left(\sum_{k=0}^{m_4-1} \frac{(m_4 x)^k}{k!}\right) + \frac{(m_4 x)^{m_4}}{m_4!} \cdot \frac{1 - x^{C_4+1}}{1-x}} \{x \geq 0\}$$

31

$$N_{S4}(x) = \frac{\sum_{k=0}^{m_4-1} k\frac{(m_4 x)^k}{k!} + \frac{m_4^{m_4}}{m_4!} \sum_{k=m_4}^{m_4+C_4} k x^k}{\sum_{k=0}^{m_4-1} \frac{(m_4 x)^k}{k!} + \frac{(m_4 x)^{m_4}}{m_4!} \cdot \frac{1 - x^{C_4+1}}{1-x}} \{x \geq 0\}$$

32

$$T_{S4}(x) = \frac{N_{S4}(x)}{x m_4 s_4 \left(1 - p_{loss4}(x)\right)} \{x \geq 0\}$$

33

$$N_{Q4}(x) = N_{S4}(x) - m_4 x \left(1 - p_{loss4}(x)\right) \{x \geq 0\}$$

34

$$T_{Q4}(x) = \frac{N_{Q4}(x)}{x m_4 s_4 \left(1 - p_{loss4}(x)\right)} \{x \geq 0\}$$

Dai grafici si vede come il numero di jobs in coda, all'aumentare dell'utilizzazione, converga a C = 8, quello dei jobs nel sistema a m_4+ C = 12 e la p_{loss} a 1:

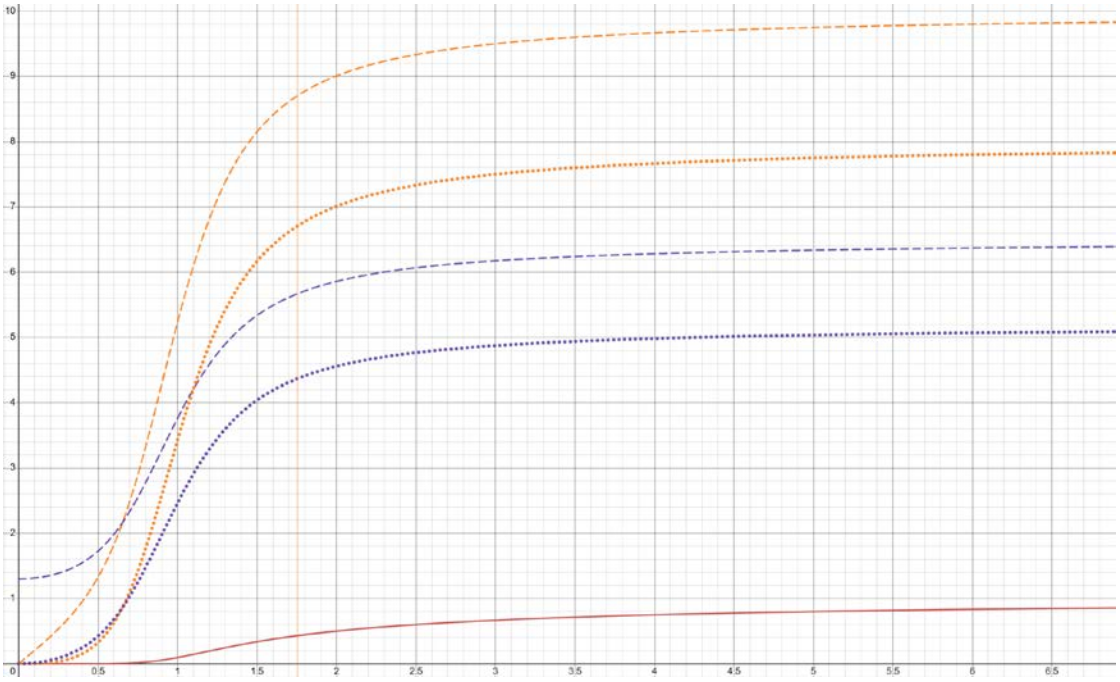

Attraverso l'utilizzo di questo strumento è stato possibile ridimensionare il sistema per identificare la configurazione ottima, l'idea alla base della ricerca è la seguente:

1. Aumentare il numero di serventi del nodo di convalida del pagamento fino a quando il QoS della probabilità di perdita non viene rispettato
    - Tutti i nodi sono stabili ($\rho < 1$) quindi il flusso entrante sul nodo di convalida rimane invariato anche se si migliorano gli altri nodi.
    - Ciò significa che la probabilità di perdita è funzione solamente del numero di serventi del nodo di convalida e della capacità della coda.
    - Infatti, un miglioramento sugli altri nodi porterebbe soltanto a una riduzione della loro utilizzazione.
2. Procedere con un algoritmo greedy fino a quando il QoS del massimo tempo di risposta non viene rispettato
    - Si aggiunge un servente al nodo che più riduce la somma dei tempi medi di risposta dei nodi del sistema.

Alla fine di quest'analisi empirica, è stata individuata la configurazione ottima che permette di minimizzare il costo totale rispettando entrambi i vincoli prefissati:

- $m_1 = 5$
- $m_2 = 6$
- $m_3 = 3$
- $m_4 = 4$

9 Analisi dei Risultati

9.1 Orizzonte Finito

L'analisi ad orizzonte finito non è necessaria ai fini del ridimensionamento ma risulta molto interessante per effettuare un'analisi dettagliata del comportamento del sistema nelle prime 24 ore di utilizzo:

- Verificare la stabilità dei nodi
- Analizzare i tempi di convergenza

Nella seguente analisi ci si sofferma sui tempi in coda e di risposta, per gli altri indici di prestazione si prega la visione dei file excel nella cartella */other/time_trend_analysis*.

Lo studio dell'andamento temporale è stato prodotto per entrambe le configurazioni, così da poter verificare se e quando gli indici prestazionali del sistema convergono al valore atteso:

- ***Nodo di prenotazione volo***

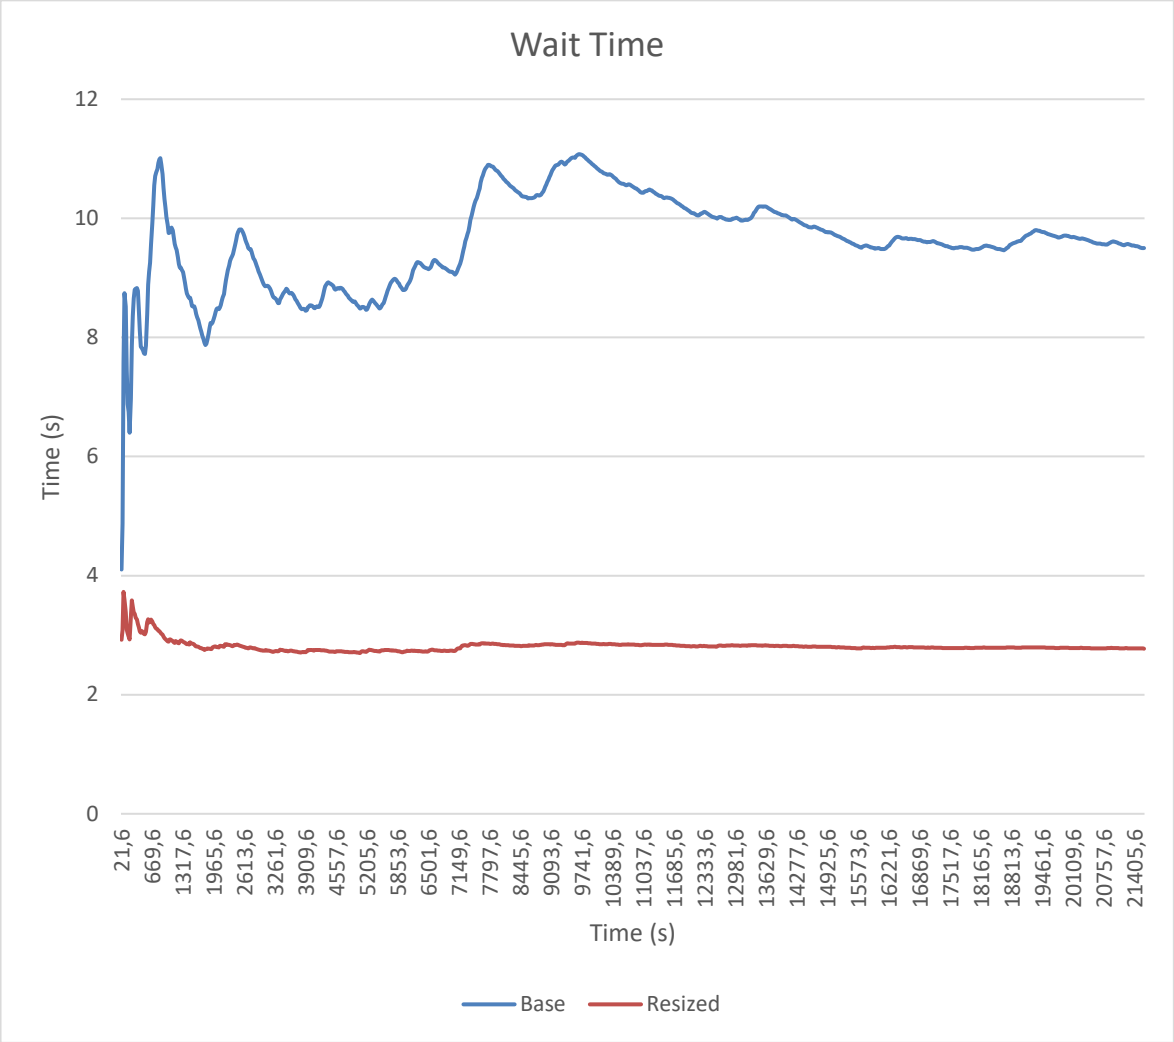

- ***Nodo di prenotazione hotel***

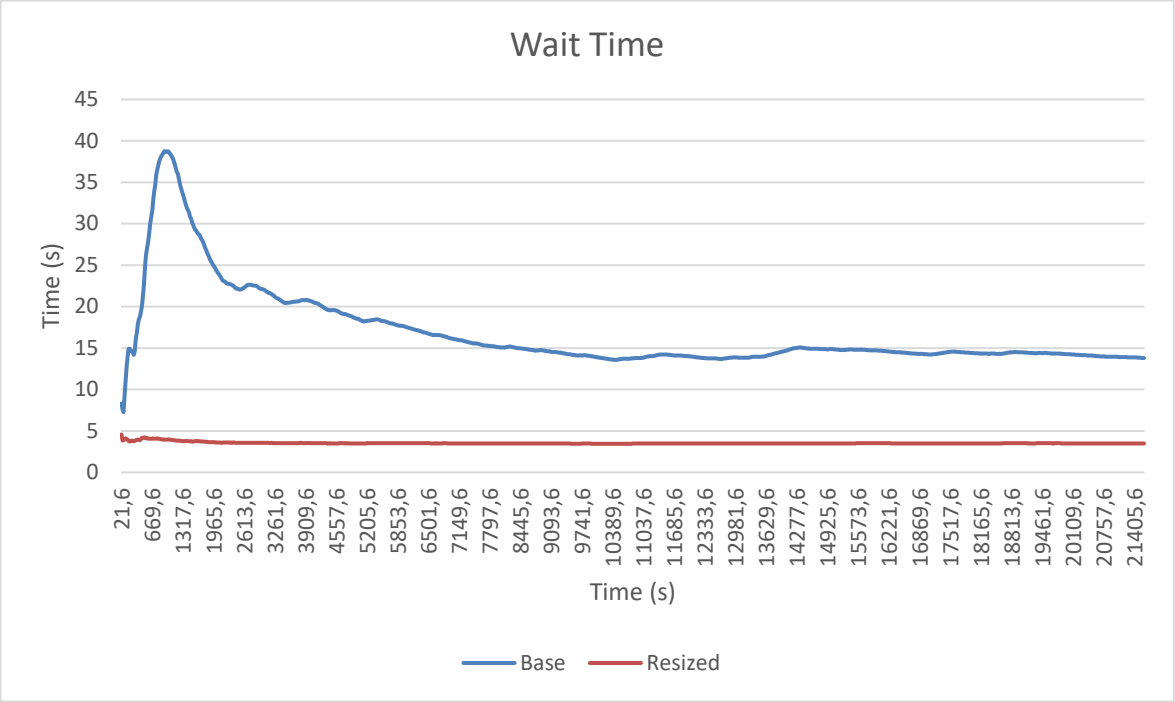

- ***Nodo di prenotazione noleggio automobili***

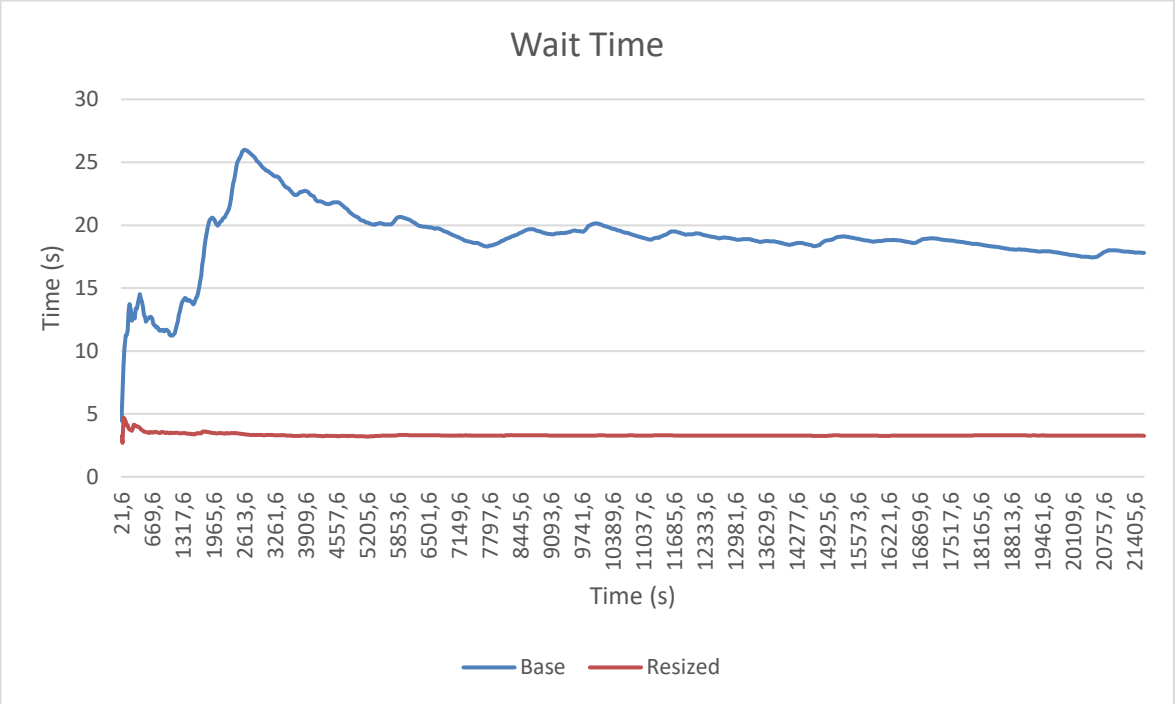

- ***Nodo di convalida pagamento***

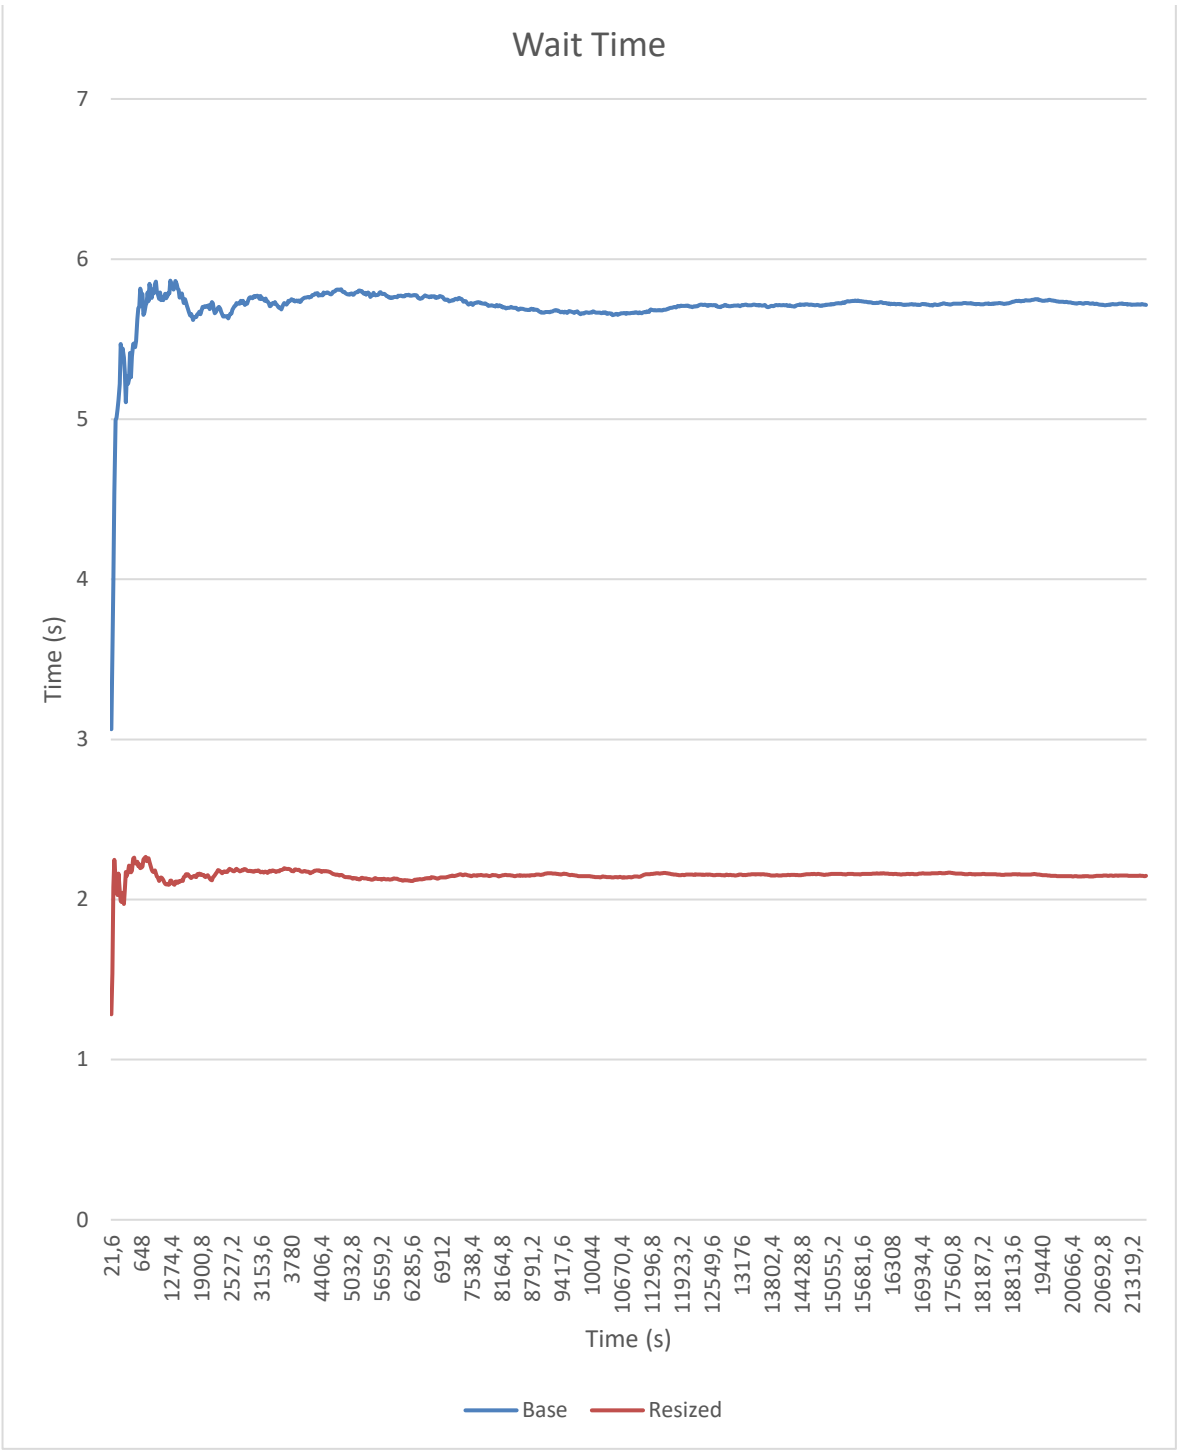
Wait Time
7
6
5
4
3
2
1
0
Time (s)
21,6
648
1274,4
1900,8
2527,2
3153,6
3780
4406,4
5032,8
5659,2
6285,6
6912
7538,4
8164,8
8791,2
9417,6
10044
10670,4
11296,8
11923,2
12549,6
13176
13802,4
14428,8
15055,2
15681,6
16308
16934,4
17560,8
18187,2
18813,6
19440
20066,4
20692,8
21319,2
Time (s)
Base
Resized

9.1.1 Prenotazioni complete

Di seguito si presentano i grafici dei tempi di risposta delle prenotazioni complete, prodotti tramite simulazioni differenti al variare del seed, in modo da comprendere più a fondo il comportamento del sistema in diversi scenari.

La durata della simulazione ad orizzonte finito è sempre relativa ad un'intera giornata, tuttavia, i grafici si concentrano su un arco temporale ridotto che mette in risalto la fase transiente:

- ***Sistema Iniziale***

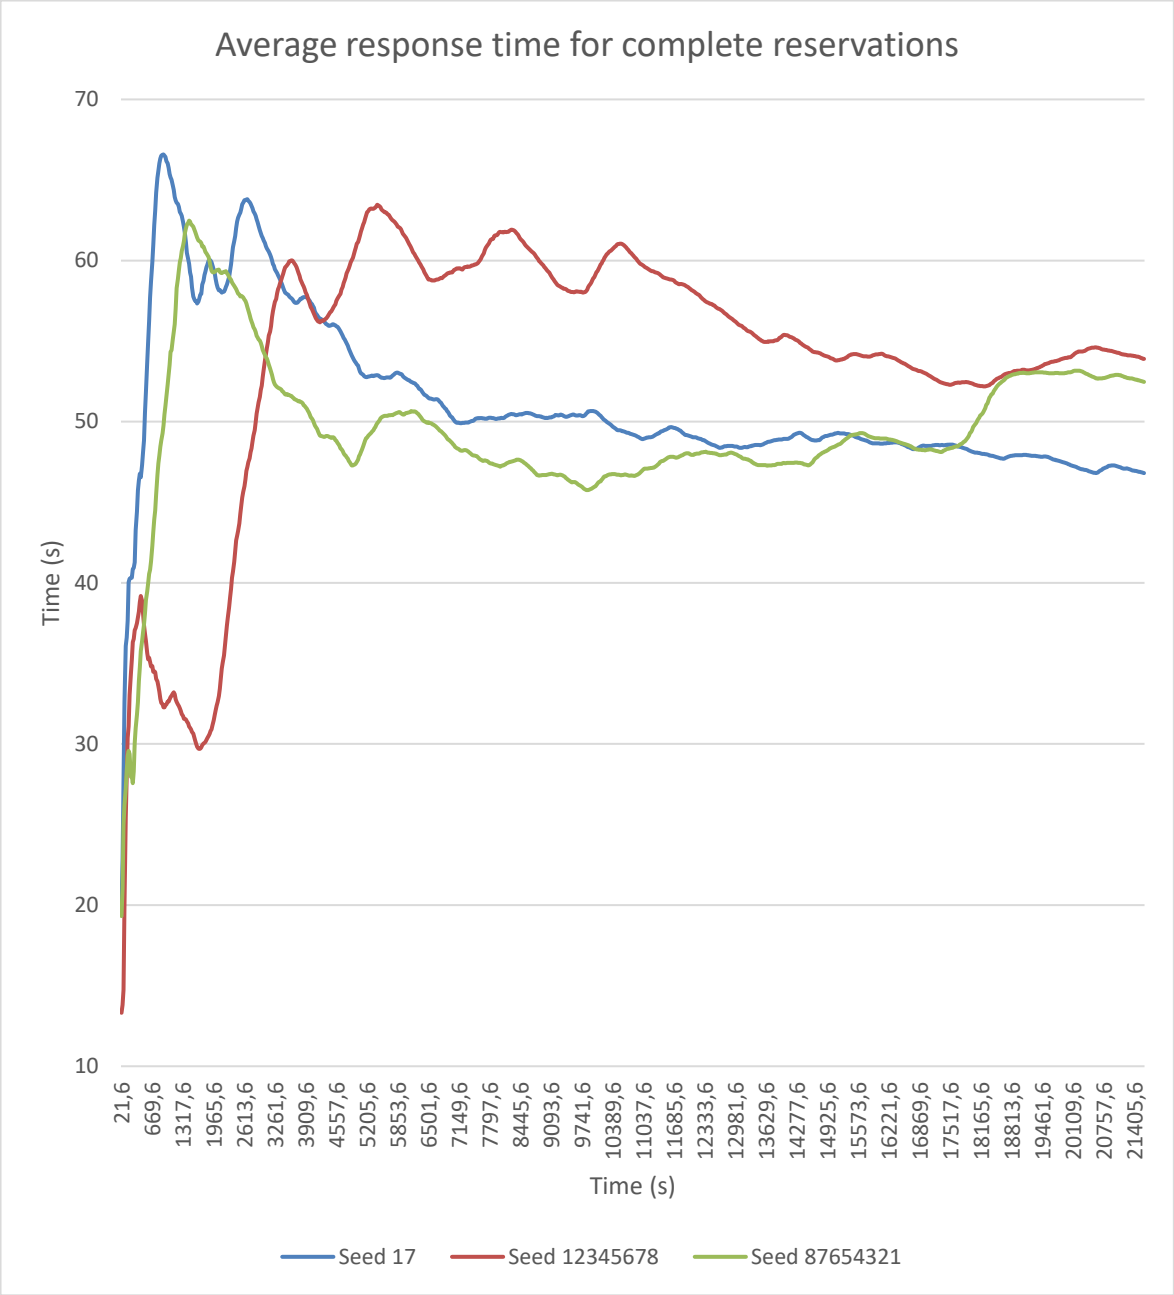

- ***Sistema Ridimensionato***

Come possiamo osservare dai grafici riportati:

- Il sistema iniziale, a causa di tassi di utilizzazione molto alti, converge molto lentamente e presenta forte variabilità
    - Improvvisi aumenti e oscillazioni ampie intorno al valore atteso.
- La configurazione ottima individuata, al contrario, offre molta più stabilità e tempi di convergenza estremamente inferiori
    - Stimata tra le due e le tre ore dall'attivazione del sistema.

9.2 Orizzonte Infinito

Come spiegato nei capitoli precedenti, il ridimensionamento del sistema è stato effettuato sfruttando il modello analitico: successivamente è stata eseguita una simulazione sul sistema ridimensionato per verificare ulteriormente la veridicità dei valori ottenuti dalle leggi teoriche.

Di seguito mostriamo il confronto prestazionale tra la configurazione di base del sistema e la nuova configurazione individuata, da cui possiamo riscontrare che entrambi i QoS sono rispettati:

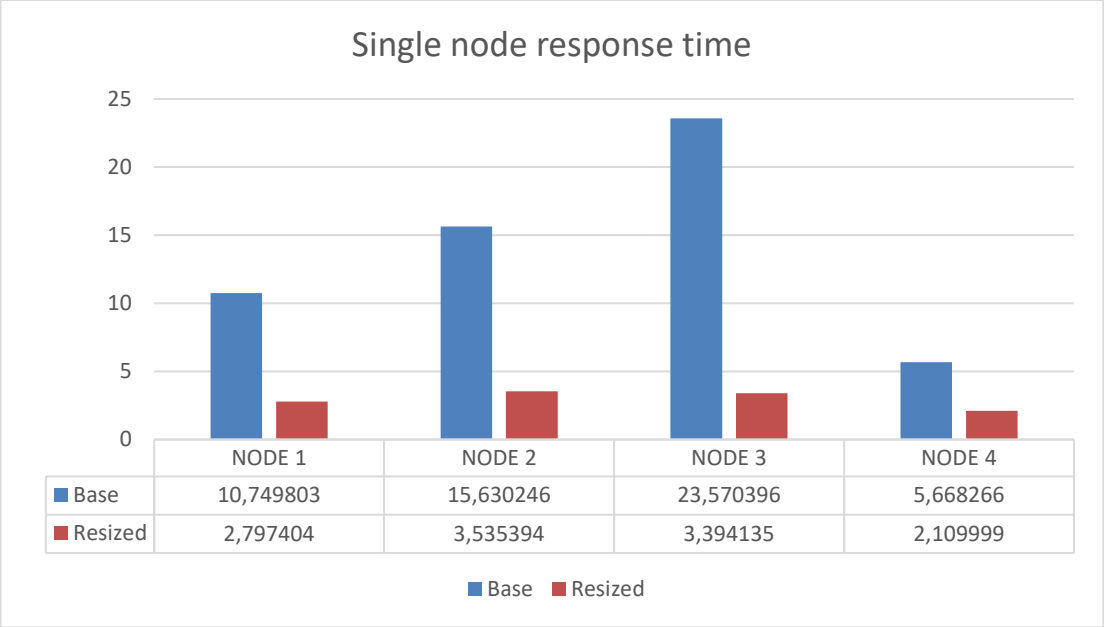

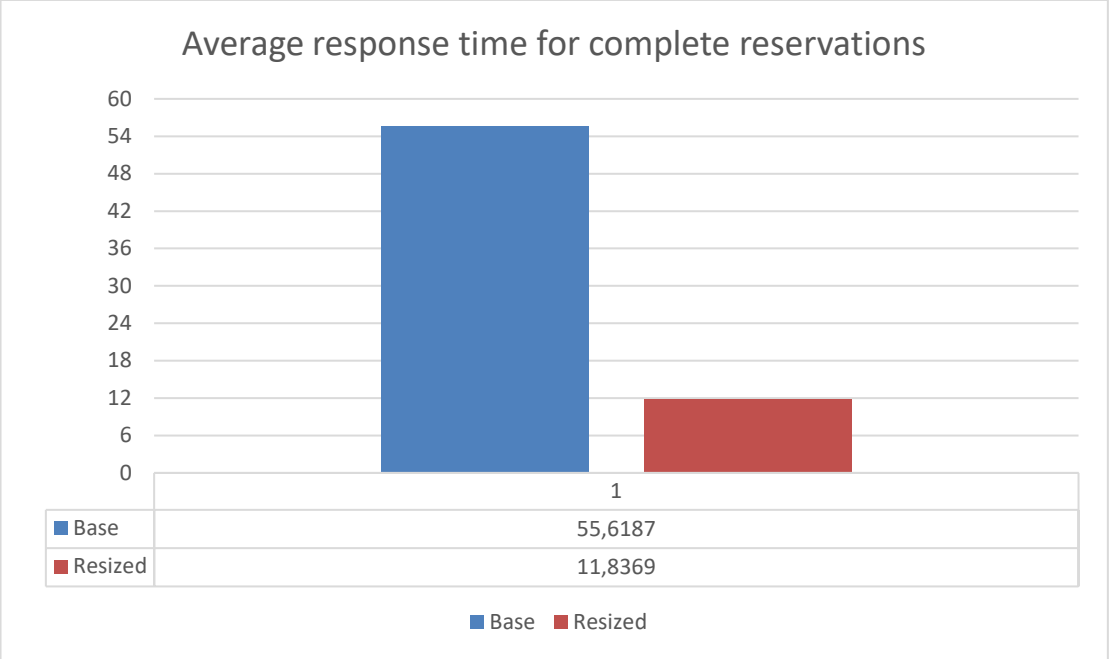

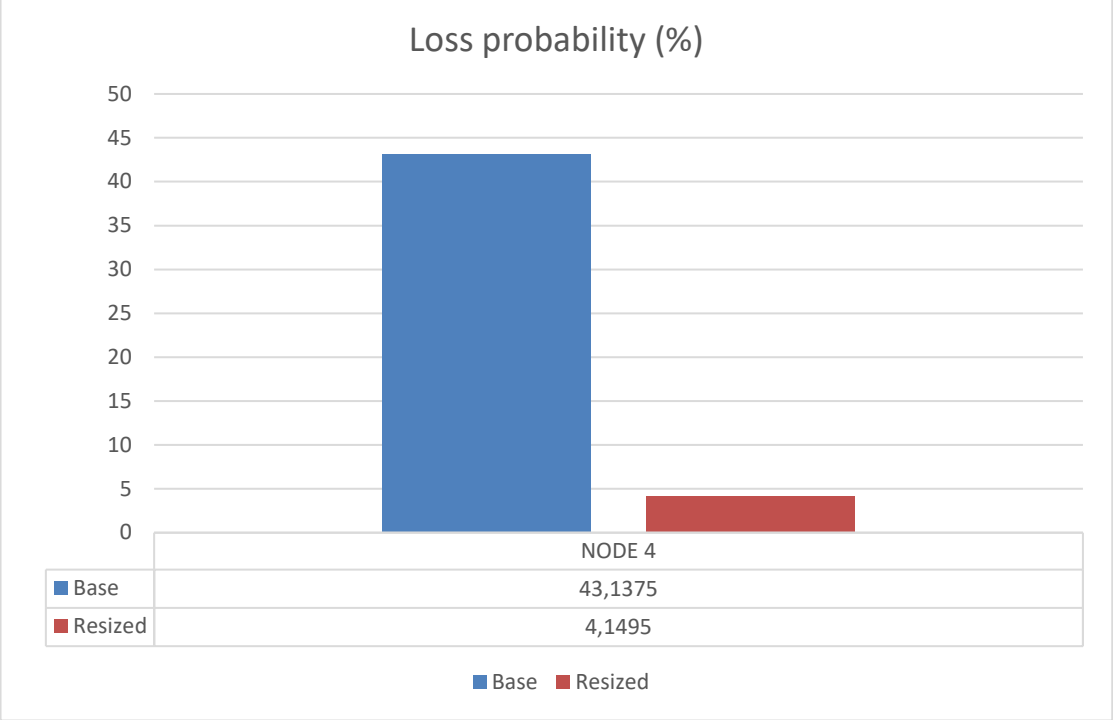
Loss probability (%)
50
45
40
35
30
25
20
15
10
5
0
NODE 4
Base
43,1375
Resized
4,1495
Base
Resized

10 Algoritmo Migliorativo

Come già accennato, il sistema è stato progettato con una coda limitata sul nodo finale di convalida del pagamento, questo per garantirne la stabilità ed evitare così ulteriori costi di sviluppo rappresentati dall'aggiunta di ulteriori serventi.

Tuttavia, anche se il QoS sulla probabilità di perdita è rispettato, una certa quantità di richieste scartate, seppur piccola, rappresenta comunque una perdita economica:

- La soluzione più logica per massimizzare il profitto sarebbe quella di introdurre una coda infinita sul nodo di convalida.
- Questo però potrebbe portare ad un aumento dei tempi di risposta del nodo in questione a tal punto da violare il QoS sulla somma dei tempi medi di risposta dei diversi nodi.

Lo scopo dell'algoritmo migliorativo, quindi, per quanto detto in precedenza, evolve nel modo seguente:

- Verificare l'effettiva violazione del QoS.
- Identificare un compromesso che permetta ad una porzione significativa degli utenti del sistema di rispettarlo con l'introduzione di code di priorità infinite.

Il sistema in esame differenzia tra *utenti visitatori* e *utenti iscritti*, questi ultimi rappresentano utenti che hanno fatto più volte uso del sistema di prenotazione, per questo motivo il miglioramento punta ad eliminare la perdita di richieste e allo stesso tempo soddisfare il QoS per gli utenti iscritti:

- Accettiamo di impiegare più tempo rispetto all'obiettivo iniziale per richieste di utenti visitatori, che sono considerate come richieste secondarie.
- Di contro, nessuna richiesta verrà persa, massimizzando il guadagno aziendale.

Il modello concettuale del sistema ridimensionato, da cui si parte per il nuovo studio su un possibile miglioramento, è il seguente:

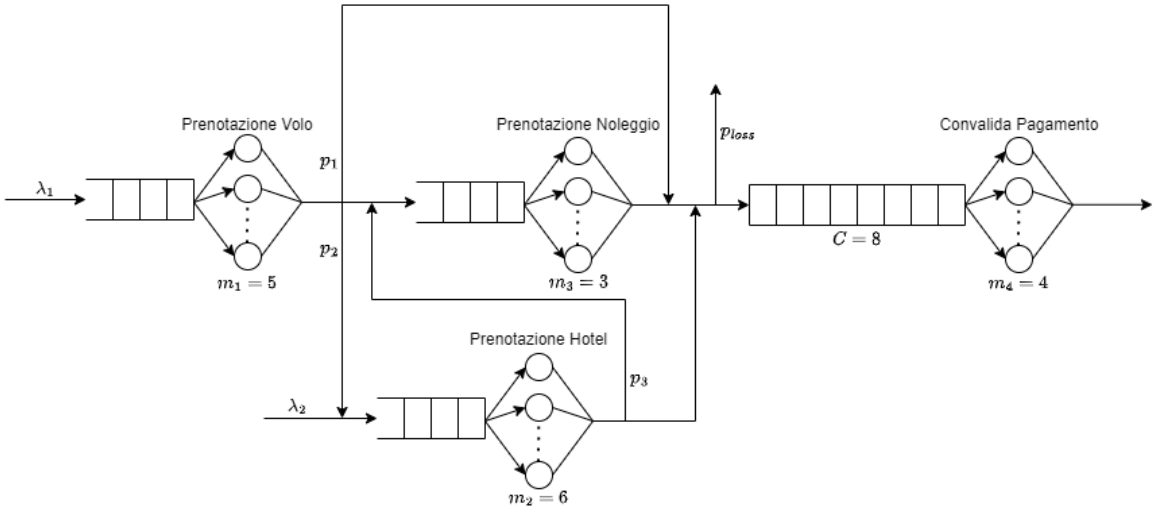

10.1 Modello Computazionale

Il modello computazionale non presenta molte differenze con il sistema iniziale e quello ridimensionato, l'unica differenza è relativa alla diversa gestione del nodo di convalida che implementa due code di priorità:

- La funzione InsertJob(), utilizzata per inserire un job nella coda di un nodo specifico, è stata modificata per gestire la priorità.
- Un job viene sempre inserito in una coda singola ma che viene gestita come due code di priorità, considerando per l'inserimento anche il livello di priorità del job oltre all'istante di tempo in cui deve verificarsi.
- La parte iniziale della coda presenta job di prima classe ordinati per tempo di arrivo, la parte finale mantiene job di seconda classe ordinati allo stesso modo.
- La coda non è divisa a metà, ma il punto di separazione dipende dalla percentuale di jobs di entrambe le classi ed evolve a runtime in base agli arrivi.

In questa maniera, saranno serviti prima tutti i jobs con priorità più alta e poi quelli con priorità più bassa, entrambi secondo una schedulazione FIFO.

10.2 Verifica

Per accertarsi che il modello computazionale è effettivamente conforme al modello delle specifiche e che i valori di output siano coerenti tra loro, sono state eseguite diverse run ad orizzonte sia finito che infinito, ma in questo caso la verifica si basa sul sistema ridimensionato in precedenza e non sulla configurazione iniziale.

Nel caso specifico è riportato l'output dell'analisi ad orizzonte infinito basata su una simulazione suddivisa in 64 batches con il 95% di confidenza:

Risultati nodo 1

Tempo di interarrivo medio	0.526896 +/- 0.005398
Tempo di risposta medio	2.794548 +/- 0.121612
Tempo di attesa medio	0.791424 +/- 0.109916
Tempo di servizio medio	2.002745 +/- 0.02038
Numero di richieste medio nel nodo	5.308439 +/- 0.238816
Numero di richieste medio nella coda	1.506199 +/- 0.211331
Utilizzazione media	0.76031 +/- 0.008587
Probabilità di perdita	0.00% +/- 0.00%

Risultati nodo 2

Tempo di interarrivo medio	0.847318 +/- 0.011624
Tempo di risposta medio	3.509001 +/- 0.072206
Tempo di attesa medio	0.323662 +/- 0.047803
Tempo di servizio medio	3.185117 +/- 0.037818
Numero di richieste medio nel nodo	4.148232 +/- 0.099895
Numero di richieste medio nella coda	0.384197 +/- 0.057833
Utilizzazione media	0.6273 +/- 0.009744
Probabilità di perdita	0.00% +/- 0.00%

Risultati nodo 3

Tempo di interarrivo medio	1.324998 +/- 0.02262
Tempo di risposta medio	3.385267 +/- 0.159745
Tempo di attesa medio	0.899245 +/- 0.135478
Tempo di servizio medio	2.485175 +/- 0.03951
Numero di richieste medio nel nodo	2.568601 +/- 0.137365
Numero di richieste medio nella coda	0.686959 +/- 0.108868
Utilizzazione media	0.627096 +/- 0.013576
Probabilità di perdita	0.00% +/- 0.00%

Risultati nodo 4

Tempo di interarrivo medio	0.386467 +/- 0.002912
Tempo di risposta medio	2.119929 +/- 0.045718
Tempo di attesa medio	0.820046 +/- 0.03683
Tempo di servizio medio	1.299774 +/- 0.012526
Numero di richieste medio nel nodo	5.479495 +/- 0.107525
Numero di richieste medio nella coda	2.117353 +/- 0.089992
Utilizzazione media	0.840484 +/- 0.008424
Probabilità di perdita	4.15% +/- 0.4083%

La verifica consiste nell'accertarsi che i flussi in arrivo ai nodi ed i tempi di servizio degli stessi, siano coerenti con quelli del modello delle specifiche prodotto dal sistema ridimensionato, che rimane del tutto invariato dal sistema iniziale:

1. Il tempo medio di inter-arrivo su un nodo deve essere uguale all'inverso del suo flusso entrante, relativamente alle probabilità di routing dichiarate nel modello delle specifiche
2. Il tempo medio di servizio deve essere pari a quello riportato nel modello delle specifiche

Di seguito è riportata la verifica:

1. $\frac{1}{flussoentrante} \approx i$
    a. $f_1 = a_1 = 1.9 \rightarrow \frac{1}{1,9} \approx 0.526896 \approx i_1$
    b. $f_2 = a_2 + p_2 f_1 = 1.18 \rightarrow \frac{1}{1,18} \approx 0.847318 \approx i_2$
    c. $f_3 = (1 - p_1 - p_2) f_1 + p_3 f_2 = 0.757 \rightarrow \frac{1}{0.757} \approx 1.324998 \approx i_3$
    d. $f_4 = ((1 - p_3) f_2 + p_1 f_1 + f_3)(1 - p_{loss}) = 2.568601 \rightarrow \frac{1}{2.568601} \approx 0.386467 \approx i_4$
2. $E(S_i) \approx specifica$
    a. $2.002745 \approx 2.0 \approx E(S_{1,i})$
    b. $3.185117 \approx 3.2 \approx E(S_{2,i})$
    c. $2.485175 \approx 2.5 \approx E(S_{3,i})$
    d. $1.299774 \approx 1.3 \approx E(S_{4,i})$

Gli ulteriori controlli di consistenza realizzati sono i seguenti:

1. La popolazione media in un nodo deve essere uguale alla somma tra quella in coda e quella mediamente in servizio (pari a m volte il tasso di utilizzazione)
2. Il tempo di risposta di un nodo deve essere uguale alla somma tra il tempo medio in coda ed il tempo medio di servizio
3. Deve valere la legge di Little
    a. La popolazione media in un nodo deve essere uguale al prodotto tra il tempo medio di risposta del nodo e il suo flusso entrante
    b. La popolazione media in coda di un nodo deve essere uguale al prodotto tra il tempo medio in coda del nodo e il suo flusso entrante

Di seguito è riportata la verifica:

1. $E(N_Q) + E(c) \approx E(N_S)$
   - $1.516170 + 5 * 0.759819 = 5.315265 \approx E(N_{S,1})$
   - $0.395549 + 6 * 0.629401 = 4.171955 \approx E(N_{S,2})$
   - $0.673888 + 3 * 0.630908 = 2.566612 \approx E(N_{S,3})$
   - $2.097162 + 4 * 0.841125 = 5.461662 \approx E(N_{S,4})$

2. $E(T_Q) + E(S_i) \approx E(T_S)$
   a. $0.797996 + 1.999562 = 2.797558 \approx E(T_{S,1})$
   b. $0.335181 + 3.200103 = 3.535284 \approx E(T_{S,2})$
   c. $0.890000 + 2.499750 = 3.389750 \approx E(T_{S,3})$
   d. $0.810357 + 1.300058 = 2.110415 \approx E(T_{S,4})$
3. $N = \lambda T$
   c. $E(N_S) = f * E(T|s) = \frac{E(T_S)}{i}$
      - $2.797558/0.526375 = 5.314762 \approx E(N_{S,1})$
      - $3.535285/0.847475 = 4.171550 \approx E(N_{S,2})$
      - $3.389750/1.320848 = 2.566344 \approx E(N_{S,3})$
      - $2.110415/0.386441 = 5.461157 \approx E(N_{S,4})$
   d. $E(N_Q) = f * E(T_Q) = \frac{E(T_Q)}{i}$
      - $0.797996/0.526375 = 1.516022 \approx E(N_{Q,1})$
      - $0.335181/0.847475 = 0.395505 \approx E(N_{Q,2})$
      - $0.890000/1.320848 = 0{,}673810 \approx E(N_{Q,3})$
      - $0.810357/0.386441 = 2{,}096975 \approx E(N_{Q,4})$

10.3 Validazione

In questa fase si vuole accertare che il modello computazionale è coerente con il sistema reale in esame, ma come già detto, non avendo dati reali a disposizione, si opera una validazione rispetto al modello analitico sul sistema ridimensionato.

Le leggi del modello analitico che caratterizzano i nodi del sistema *sono le stesse descritte nel capitolo 7*, quindi verifichiamo che effettivamente il modello computazionale è coerente con il modello analitico:

	Modello Analitico	**Modello Sperimentale** ($\alpha = 0.01$)
$E(N_{S,1})$	5.3187147868627	5.308439 +/- 0.238816
$E(N_{S,2})$	4.17165922544946	4.148232 +/- 0.099895
$E(N_{S,3})$	2.567799278676707	2.568601 +/- 0.137365
$E(N_{S,4})$	5.46083122987232	5.479495 +/- 0.107525
$E(T_{Q,1})$	0.799323572033	0.791424 +/- 0.109916
$E(T_{Q,2})$	0.335304428347	0.323662 +/- 0.047803
$E(T_{Q,3})$	0.892073023351	0.899245 +/- 0.135478
$E(T_{Q,4})$	0,81066019671	0.820046 +/- 0.03683
p_{loss}	4.14954715564 %	4.1489% +/- 0.4083%
$E(T_{S,tot})$	11.8373612204	11.8087 +/- 0.24

10.4 Analisi dei Risultati

Attraverso le simulazioni effettuate, è stato possibile individuare la percentuale massima di utenti privilegiati rispetto al totale delle utenze per cui il QoS sulla somma dei tempi medi di risposta dei diversi nodi non sia violato ($E(T_S) < 12$):

- Tale percentuale risulta essere pari a circa **85.69%**
- Fino a quando gli iscritti non supereranno tale valore rispetto al totale, il QoS sarà rispettato
- Il vantaggio principale è che la probabilità di perdita viene azzerata grazie all'uso di code infinite, garantendo l'assenza di scarto di richieste

10.4.1 Orizzonte Finito

L'unico nodo modificato rispetto alla configurazione di partenza è quello relativo alla convalida dei pagamenti, pertanto, si propone innanzitutto un'analisi che si concentra esclusivamente sull'ultimo nodo:

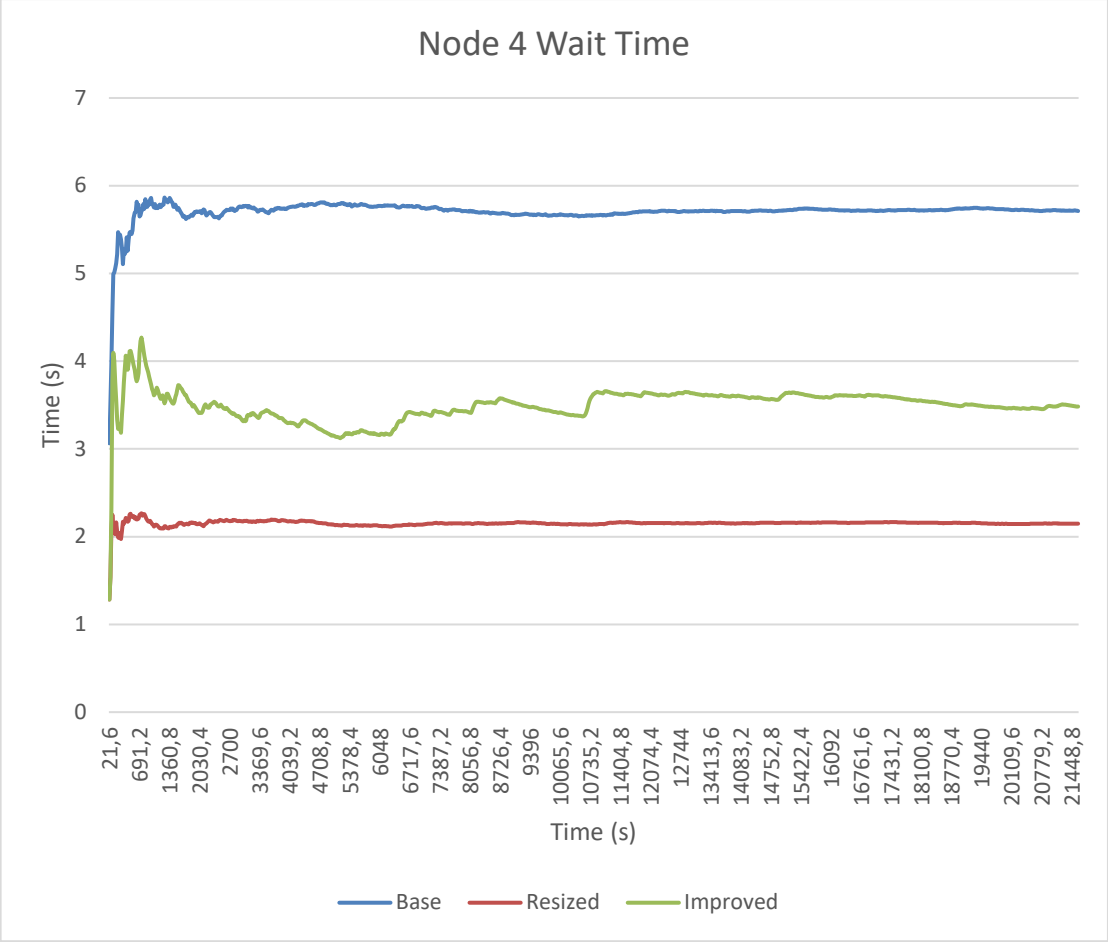

L'aggiunta di una coda infinita garantisce di non rigettare alcuna richiesta e quindi inevitabilmente aumenta l'utilizzazione del nodo, impattando sulla sua stabilità. Infatti, dai grafici è evidente come questa sia estremamente più variabile e più lenta a convergere al valore atteso rispetto alla configurazione base e ridimensionata, che invece erano caratterizzati da una coda limitata.

L’aumento del tasso di utilizzazione dell’ultimo nodo si riflette sul comportamento del sistema, infatti, l’introduzione di una coda infinita aumenta di molto il numero di richieste processate, che si traduce in un incremento non trascurabile del tempo di attesa medio sperimentato per richieste di prenotazioni complete:

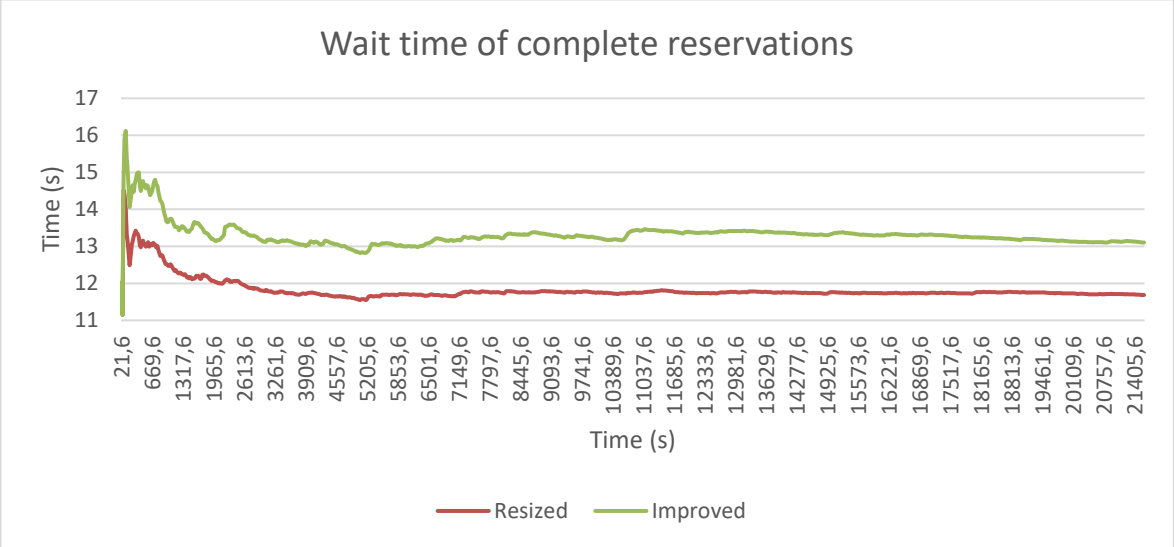

10.4.2 Orizzonte Infinito

Come si evince dai grafici, i tempi peggiorano e il QoS non è più rispettato, tuttavia, utilizzando due code di priorità, è possibile rispettarlo per la maggior parte degli utenti, ovvero quelli iscritti:

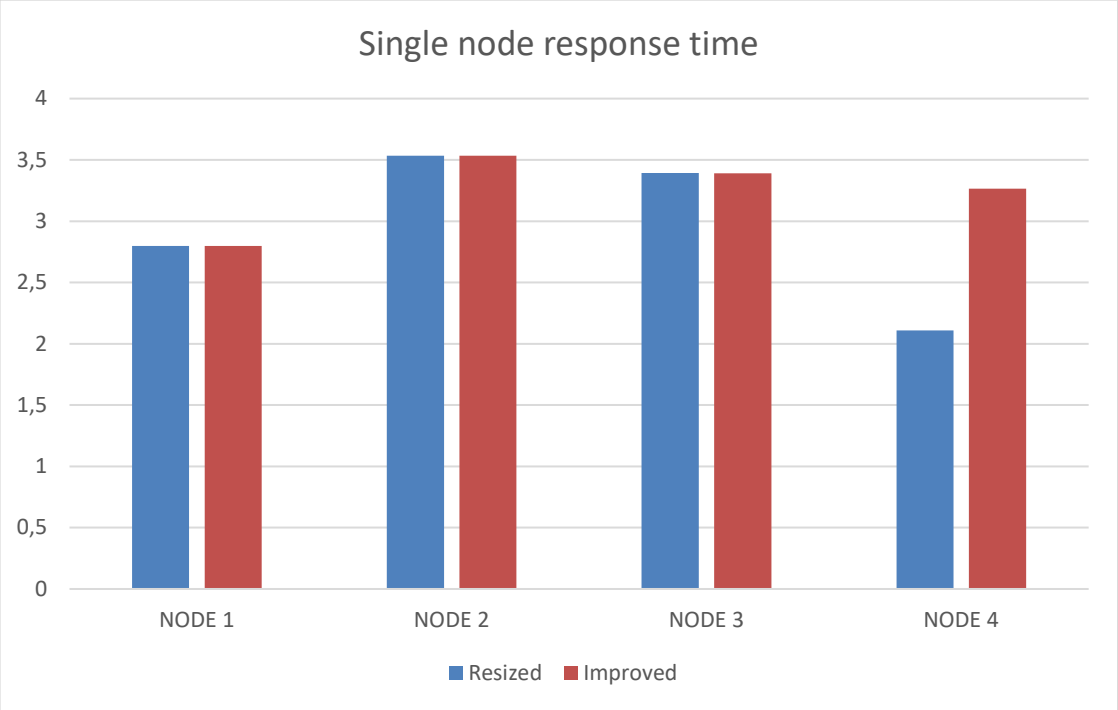

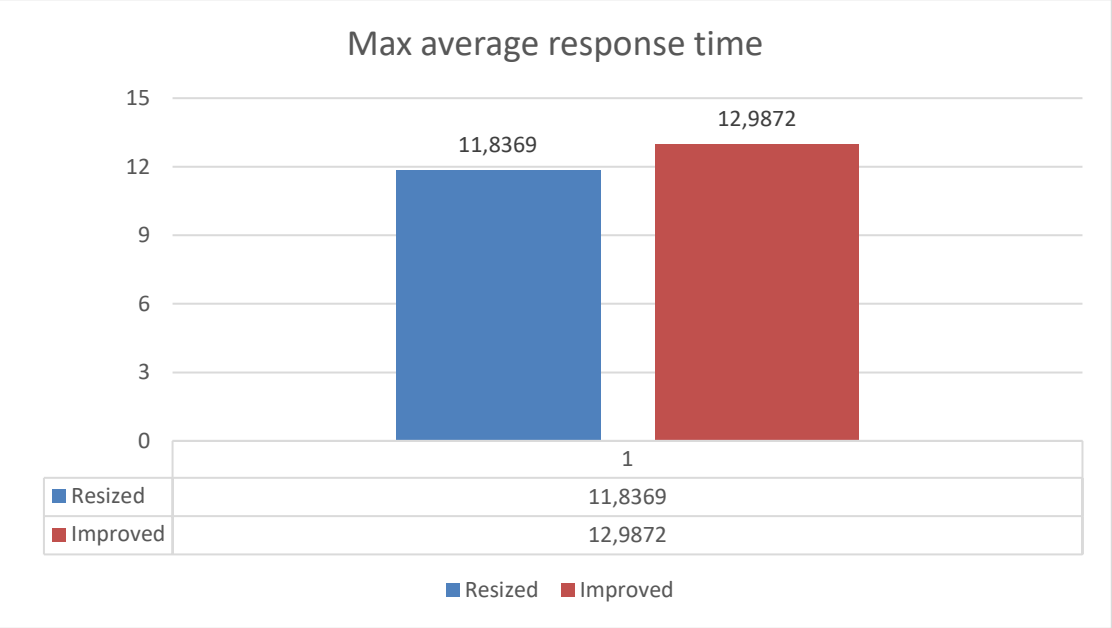

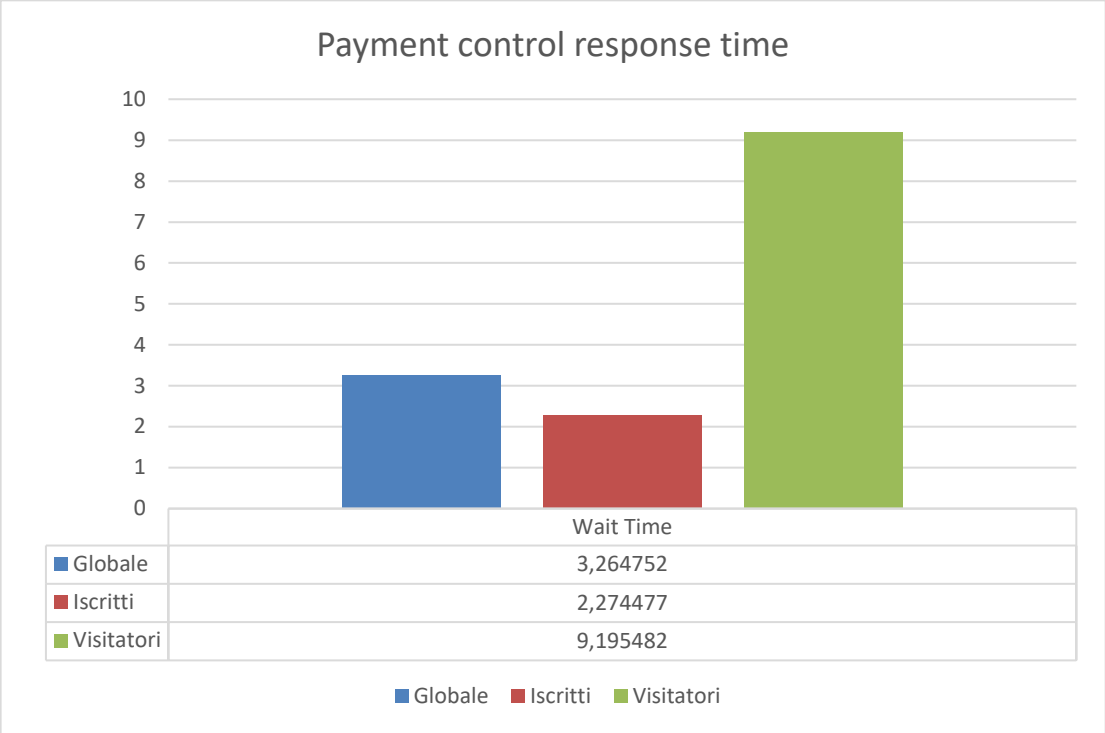
Payment control response time
10
9
8
7
6
5
4
3
2
1
0
Wait Time
Globale 3,264752
Iscritti 2,274477
Visitatori 9,195482
Globale Iscritti Visitatori

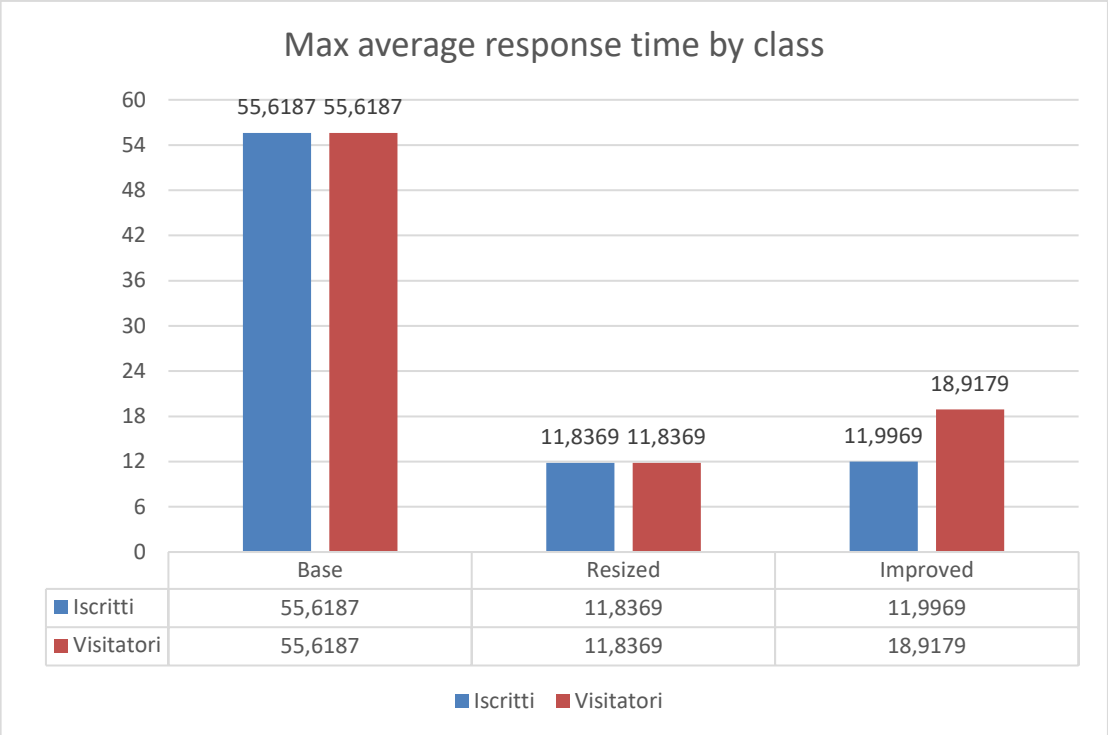
Max average response time by class
60
54
48
42
36
30
24
18
12
6
0
55,6187 55,6187
11,8369 11,8369
11,9969
18,9179
Base Resized Improved
Iscritti 55,6187 11,8369 11,9969
Visitatori 55,6187 11,8369 18,9179
Iscritti Visitatori

10 Conclusioni

Sia per il sistema ridimensionato che per quello migliorato la configurazione ottima è la seguente:

- $m_1 = 5$
- $m_2 = 6$
- $m_3 = 3$
- $m_4 = 4$

La nuova topologia dell'architettura, per introdurre un ulteriore miglioramento del sistema, è la seguente, illustrata in figura:

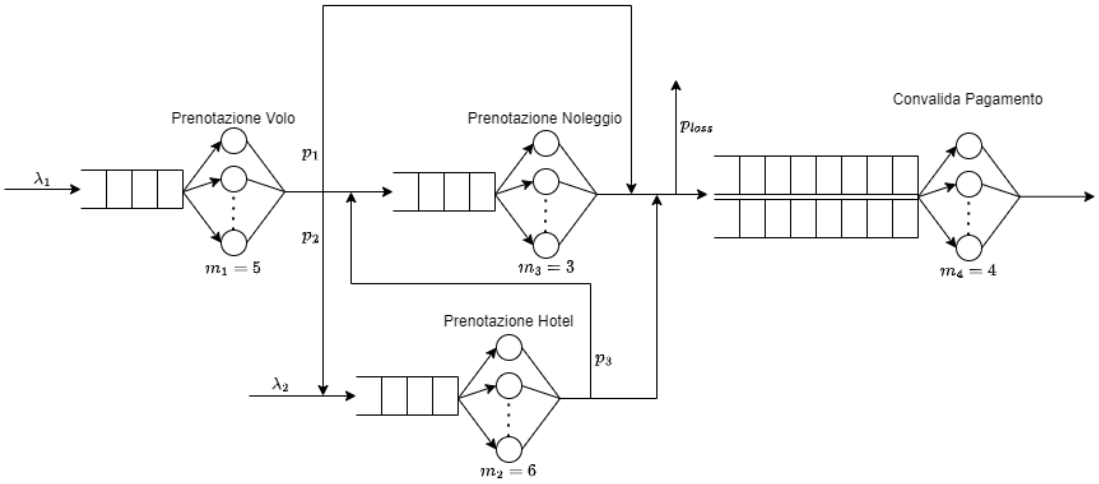

La soluzione migliorativa è una sorta di compromesso tra gli obiettivi prefissati e le richieste dell'azienda, lo scopo è quello di individuare una particolare configurazione che permettesse di eliminare la perdita di richieste e allo stesso tempo soddisfare il QoS sul tempo sperimentato per prenotazioni complete per gli utenti iscritti:

- Il vantaggio è quello di ottenere un guadagno economico grazie all'assenza di scarto di richieste, garantito dall'introduzione di code infinite.
- Di contro, il primo QoS è rispettato per circa l'85% degli utenti (*iscritti*), i restanti 15% (*visitatori*) sperimenteranno tempi di risposta maggiori.

A questo punto, l'azienda che ha commissionato il lavoro ha a disposizione due possibili configurazioni per il sistema da poter adottare in base alle esigenze:

- Se l'obiettivo è guadagnare il più possibile, si utilizzerà la configurazione migliorata evitando scarti di richieste, e quindi perdite economiche.
- Altrimenti, si utilizzerà la configurazione ridimensionata garantendo tempi di risposta più brevi, ma accettando di avere perdite economiche per scarti di richieste.

Riferimenti

[1] Hill, R. Discrete-Event Simulation: A First Course. J Simulation 1, 377, 2004.

[2] Hill, R. Discrete-Event Simulation: A First Course. J Simulation 1, 380, 2004.